

西洋棋引擎對戰結果之數理統計與演算法分析

本文件旨在針對西洋棋引擎對戰的 PGN 數據，建立嚴謹的數學與統計模型，並解釋各項統計量在西洋棋演算法評估中的實質意涵。

1. 期望得分與 Elo 分數轉換 (Elo Rating System)

西洋棋對局的結果屬於離散的隨機變數 $X \in \{1, 0.5, 0\}$ (分別對應勝、和、負)。經過大量獨立試驗後，計算其樣本均值，即期望得分率 E 。

在 FIDE 規範與電腦西洋棋領域中，引擎間的實力差距假設遵循邏輯斯諦分佈 (Logistic Distribution)。Elo 分數差距 ΔR 與得分期望 E 的關係定義為：

$$E = \frac{1}{1 + 10^{-\Delta R/400}}$$

透過逆向運算，我們將勝率空間 $\mathbb{R}_{[0,1]}$ 映射至 Elo 差距空間 $\mathbb{R}$ ：

$$\Delta R = -400 \log_{10} \left(\frac{1}{E} - 1 \right)$$

信賴區間推導：為了量化有限樣本的估計誤差，我們計算隨機變數 X 的樣本變異數 σ^2 。根據中央極限定理 (Central Limit Theorem)，當樣本數 N 夠大時，樣本均值的抽樣分佈漸近於常態分佈 $\mathcal{N}(E, \sigma^2/N)$ 。取 95% 信賴水準 (對應 $Z_{0.975} \approx 1.96$)，我們可得到期望得分 E 的置信區間。將此區間端點代入 Elo 轉換函數，即可得到評估引擎實力差距的**誤差界限 (Margin of Error, MoE)**。

2. 累積勝場與表現穩定性分析 (Cumulative Trajectory)

累積勝場圖描述了一個離散時間序列過程 $W(N) = \sum_{i=1}^N I(X_i = 1)$ ，其中 I 為指示函數 (勝局為 1，否則為 0)。

- 平穩性檢驗：**若引擎的演算法在整個測試週期內表現一致，其獲勝機率應具備獨立同分佈 (i.i.d.) 特性。巨觀上， $W(N)$ 會收斂於一條斜率為期望勝率 P_{win} 的直線。
- 偏差判讀：**實際曲線會圍繞理論均值線產生隨機波動。若曲線在某個對局區間出現斜率的顯著改變 (大幅偏離均值線)，則暗示引擎的表現並不穩定，可能存在特定開局庫被克制、或者是快取 (Hash Table) 管理不當導致的評估偏差。

3. 執色優勢與獨立性檢定 (Color Bias & Chi-Square Test)

西洋棋中白方享有先手優勢。為了驗證此優勢對演算法勝率的實質影響程度，我們建立虛無假設 H_0 ：「比賽結果與執色條件獨立」。透過建構 2×3 的列聯表並計算皮爾森卡方統計量 (Pearson's Chi-squared statistic)：

$$\chi^2 = \sum \frac{(O_{ij} - E_{ij})^2}{E_{ij}}$$

當計算得出的 p -value 顯著低於顯著水準（如 < 0.05 ）時，我們拒絕 H_0 。這在引擎分析中代表該引擎的評估函數（Evaluation Function）高度依賴先手展開優勢；反之，若 p -value 較高，則說明引擎的防禦演算法極為出色，能有效消弭後手劣勢。

4. 主流開局效率與雙比例 Z 檢定 (Opening Efficiency)

評估引擎對不同開局（如 1. e4 與 1. d4）的掌握度時，需採用雙比例 Z 檢定（Two-Proportion Z-Test）來確認勝率差異是否具備統計顯著性，而非單純比較兩者的勝率均值。

定義合併比例（Pooled Proportion） $\bar{p}$ ，檢定統計量為：

$$Z = \frac{p_1 - p_2}{\sqrt{\bar{p}(1 - \bar{p})\left(\frac{1}{n_1} + \frac{1}{n_2}\right)}}$$

若 p -value 大於顯著水準（例如 > 0.05 ），表示兩者的期望獲利在統計上無顯著差異。這代表引擎的極小化極大演算法（Minimax）在處理這兩種初始決策樹時，搜尋效率與盤面評估深度相當，未出現某種開局存在系統性弱點的狀況。

5. 對局步數分佈與終結效率 (Game Length Distribution)

對局總步數 L 反映了引擎在狀態空間中搜尋至「終局判定（Terminal Node）」所需的回合數。透過分析不同賽果的均值（ μ ）與標準差（ σ ），可評估引擎的剪枝與防禦特徵：

- 非對稱的步數均值：**通常 $\mu_{win} < \mu_{loss}$ 。當引擎偵測到強制獲勝路徑（Mate-in-N）時，會選擇最短路徑終結遊戲；反之，處於劣勢時，引擎會選擇將距離被將死步數最大化的路徑，盡可能拖延回合數。
- 和局的雙峰特徵：**和局的標準差 σ_{draw} 通常顯著大於勝負局。這是因為和局由兩種截然不同的賽況組成：一是開局不久即觸發的「強制重複局面（Threefold Repetition）」；二是進入殘局後雙方形成堅固防線，直到觸發「50 步規則（50-move rule）」的漫長對局。

6. 賽果序列獨立性與記憶效應 (Sequence Independence)

為確保每次對局的客觀性，我們檢驗賽果序列是否具備獨立性，排除引擎因保留上局狀態（如未清除的 Transposition Table）而產生的干擾。

- 一階自相關係數 (Lag-1 Autocorrelation, $\rho(1)$):** 測量前一局賽果對下一局的線性影響。
- 沃爾德-沃爾福威茨游程檢定 (Wald-Wolfowitz Runs Test):** 檢查連續出現同一結果的長度是否符合純隨機分佈。若通過檢定（ p -value > 0.05 ），證明引擎的每次對戰皆為獨立隨機試驗，不存在系統性的連勝或連敗慣性。

7. 統計指標與數值判讀對照表

以下表格彙整了上述各項分析中出現的核心統計指標，並定義其數值區間在西洋棋引擎測試中的嚴格意涵。

統計指標 (Indicator)	數值範圍 / 判讀區間	意義與演算法特徵解釋
期望得分 (E)	$E > 0.55$	測試引擎具備顯著優勢，勝率穩定壓制對手。
	$0.45 \leq E \leq 0.55$	雙方實力接近，落於測量誤差邊緣。
	$E < 0.45$	測試引擎處於明顯劣勢。
Elo 差距 (ΔR)	$\Delta R > +100$	存在代差級別的實力差距（勝率約 64% 以上）。
	$-30 \leq \Delta R \leq +30$	實力基本對等，可能只是同一引擎的不同參數微調版本。
95% 誤差界限 (MoE)	$MoE < 15$	樣本數極為充足（通常需數千局），評估結果高度可信。
	$15 \leq MoE \leq 35$	標準測試範圍（如 500-1000 局），數據具備統計意義。
	$MoE > 50$	樣本數過少或和局率極高，Elo 計算結果不具參考價值。
卡方檢定 p -value	$p < 0.01$	高度相關： 存在極為顯著的先手優勢，引擎非常依賴白方主動權。
(執色獨立性)	$0.01 \leq p < 0.05$	中度相關： 具備一般的先手紅利。
	$p \geq 0.05$	無顯著相關： 引擎防禦演算法極佳，黑白方勝率無統計學上的明顯差異。
Z 檢定 p -value	$p < 0.05$	兩種開局的期望獲利存在實質差異，引擎對其中一種開局有明顯的評估盲點或優化。
(開局效率差異)	$p \geq 0.05$	引擎對受測的數種開局掌握度相當，探索樹收斂至相似的勝率期望。
自相關係數 ($\rho(1)$)	$\rho(1) > 0.1$	正相關： 存在「連勝/連敗」慣性，暗示引擎快取未清除或狀態殘留。
	$-0.05 \leq \rho(1) \leq 0.05$	無相關： 對局之間完美獨立，賽果無記憶效應。
游程檢定 p -value	$p < 0.05$	賽果序列非隨機，可能受特定時間點的系統負載、環境因素或對局配對規則影響。
(隨機性檢定)		